

현대오토에버 모빌리티 SW 스쿨 4기

K-건축 여행 도감

스마트팩토리 머신 비전 프로젝트

Team 5조

이태인, 지태현, 최승재, 허민엽, 최유성



목 차

01

주제 선정 이유

02

데이터 수집 과정

03

데이터 전처리

04

모델 소개

05

실험 결과 및
분석

06

한계 및 보완
방향

01 주제 선정 이유

HYUNDAI
AutoEver



01 주제 선정 이유



02 데이터 수집

02 데이터 수집 과정 | train set

데이터 수집 방법

- 수동 캡처

- 수동 캡처 기준

항목	기준
객체 수	이미지당 객체 1개만 포함
해상도	최소 300×300 이상 (학습 시 224×224 resize 대응)
촬영 각도	정면, 측면, 약 45° 다양하게 포함
배경	단색 또는 단순 배경 우선 수집
클래스 기준	형태 정의에 부합하는 이미지만 포함

- Web 크롤링

- 네이버 쇼핑 API - 키 발급 불가능
- 네이버 검색 이미지 부문 API 키 발급
- icrawler.BingImageCrawler를 활용하여 클래스별 키워드로 이미지 수집
- 크롤링 이미지 한계
 - 하나의 이미지에 여러 개 객체 포함
 - 클래스 레이블과 실제 형태 불일치
 - 배경, 텍스트, 광고 요소 과다



02 데이터 수집 과정 | train set

데이터 수집 전략

각 팀원이 각자 다른 사이트에서 4개 클래스 데이터 모두 수집

- 빠른 데이터 확보
- 중복 · 편향 방지를 위해 출처(사이트) 분리 (네이버 쇼핑, SSG 몰, 구글, 쿠팡, G마켓)
- 각자 4개 클래스 전부 수집 → 모든 클래스가 사이트 별 다양성을 균등하게 확보 가능

출처	mug	straight	taper_smooth	taper_step	Total
네이버 쇼핑	32	35	29	34	130
SSG 몰	34	37	30	31	132
구글	40	40	36	35	151
쿠팡	39	38	34	33	144
G마켓	36	39	38	30	143
Total	181(25.8%)	189(27.0%)	167(23.9%)	163(23.3%)	700

총 700개의 train 데이터 셋 확보

02 데이터 수집 과정 | test set

Test 데이터 수집

- 실촬영 데이터에서의 일반화 성능 검증을 위해 수집

Class	개수
mug	22
straight	39
taper_smooth	32
taper_step	33
Total	126

총 126개의 Test 데이터 셋 확보

02 데이터 수집 과정

데이터 예시 (크롤링 학습 데이터 / 실촬영 테스트 데이터)

mug



straight



taper_smooth



taper_step



03 데이터 전처리

1단계. 크롤링 데이터 품질 필터링

Rule-based	Mask R-CNN	이미지 필터링 판단
정답 O	정답 O	유지
정답 O	정답 X	유지
정답 X	정답 O	유지
정답 X	정답 X	버림

라벨 품질 필터링 — 신호 유형별 예시 (원본 + 룰베이스/Mask R-CNN 마스크)



03 데이터 전처리

2단계. 이미지 방향 메타데이터 정규화

- 직접 촬영한 158장 중 13장이 가로로 되어있음
- 이미지를 세로로 회전시키고 이미지가 가진 메타 데이터도 세로로 정규화함

EXIF 방향 정규화 — 회전 전/후 실제 사진

회전 전 (raw 픽셀, EXIF 태그 무시하고 읽음)
크기: 4000x3000 (가로)



회전 후 (정규화됨, 픽셀 자체가 회전 반영)
크기: 3000x4000 (세로)




03 데이터 전처리

3단계. 배경-객체 색상 유사 이미지 제거

- 직접 촬영한 158장 중 32장은 객체와 배경의 색상이 비슷해 구분이 어려운 사진이었음
- 평가 데이터의 품질을 높이기 위해 해당 32장을 제거 → 126장으로 정리

배경과 비슷한 객체 예시



03 데이터 전처리

전처리 후 데이터 개수

- 크롤링 데이터
 - 전처리 전 개수: 총 700개
 - 전처리 후 개수: 총 642개
- 직접 찍은 데이터
 - 전처리 전 개수: 총 158개
 - 전처리 후 개수: 총 126개

Class	크롤링 데이터		실촬영 데이터
	train	test	test
mug	139	34	22
straight	141	35	39
taper_step	116	29	33
taper_smooth	119	29	32
합계	515	127	126

04 모델 소개

01 Baseline

Rule-based

기하학적 특성 기반 규칙 판정 모델

02 CNN Baseline

ResNet-18

잔차 학습 기반의 경량 CNN 모델

03 Efficient CNN

EfficientNet-B0

Compound Scaling 적용 최적화 모델

04 Lightweight CNN

MobileNetV3-Small

모바일/임베디드 최적화 경량 모델

05 Transformer

ViT (Vision Transformer)

Self-Attention 기반 비전 트랜스포머

06 Modern CNN

ConvNeXt-Tiny

ViT 구조를 반영한 현대적 CNN 모델

01 Baseline

Rule-based

기하학적 특성 기반 규칙 판정 모델

HYUNDAI
AutoEver



04 사용 모델 | Rule-based

마스크 생성 및 계산 방식

1. 이미지를 토대로 마스크 생성 (Otsu + Canny → GrabCut)
2. 마스크를 세로 10구간으로 분할
3. 구간 별 흰색 픽셀 개수 측정

마스크 생성 파이프라인 — Otsu / Canny / GrabCut 단계별 결과


원본




Otsu
명도 기준 자동 이진화
(밝기 대비 큰 배경에 강함)



Canny
엣지(경계선) 검출
(그림자·저대비 배경에 강함)



GrabCut
Otsu+Canny를 시드로
색 분포 기반 최종 정제
(최종 마스크)



04 사용 모델 | Rule-based


판정 순서

1	높이 / 지름 ≤ 1.5	mug
2	아래폭 / 위폭 ≥ 0.9	straight
3	단차 비율 > 0.3	taper_step
4	else	taper_smooth

• 단차 비율 계산:

- deltas = 각 인접 구간 사이 폭 감소량
- 전체 감소량 = 위쪽 폭 - 아래쪽 폭
- 단차 비율 = deltas 최대값 / 전체 감소량

틀베이스 판정 기준 — 클래스별 실제 예시



04 사용 모델 | Rule-based

한계


1. 그림자 및 받침대 등이 전경으로 잘못 인식되어
폭 프로파일 전체가 뒤틀림
2. 객체 색상과 비슷한 배경이면 세그멘테이션이 잘 되지 않음
3. 2D 폭 프로파일 방식 자체가
“물체가 정확히 정면에서 깨끗하게 분리된다”는 전제에 의존 =>
이 전제가 깨지는 순간 구조적으로 매우 취약해짐

를베이스 마스크 파이프라인의 대표적인 실패 사례

① 그림자 세그멘테이션
바닥에 번진 반사/그림자가 물체 아래쪽에
넓은 얼룩으로 붙어서 함께 마스크에 잡힘
(아래쪽이 부풀려져 straight로 오분류)




마스크 -> 판정: 직선 원통형 (X, 실제: 단차 테이퍼형)



② 배경-객체 색상 유사
흰색 물체 + 흰색/연회색 배경
색상 차이가 거의 없어 마스크 전경 비율 4.2%로 하락
(경계를 거의 못 잡음, mug로 오분류)



마스크 -> 판정: 머그형 (X, 실제: 연속 테이퍼형)



02 CNN Baseline


ResNet-18

잔차 학습 기반의 경량 CNN 모델

HYUNDAI
AutoEver



04 사용 모델 | ResNet-18



ResNet-18 아키텍처

ResNet-18

- Skip Connection 구조로 깊은 층도 기울기 소실 없이 안정적으로 학습하는 CNN 계열

선택 이유

- 적은 데이터에도 강함: 전이학습 특징을 활용하여 소규모 학습셋만으로 학습 가능
- 가벼운 구조: 18개 레이어로 구성, 약 1170만개 파라미터로 구성되어 다른 CNN 모델보다 상대적으로 가벼움

모델	ResNet-18
Pretrained weight	ImageNet Pretrained
크롤링 데이터셋 (전체/학습/테스트)	642 / 513 / 129
실촬영 데이터셋 (테스트)	126
입력크기	224 × 224
Epoch / batch	20 / 32
Optimizer	Adam, LR: 0.003
loss function	Cross Entropy Loss


04 모델 개선 과정 | ResNet-18

1. 개선 1 : 백본 파인튜닝 & 차등 학습률

- 백본까지 파인 튜닝 (Unfreeze) 적용
- 백본 레이어마다 차등 학습률 적용

2. 개선 2 : TTA (Test-Time Augmentation) 적용

- 하나의 테스트 이미지에 대해 여러 버전으로 변형하여 예측
- 변형된 이미지들의 예측 결과의 평균을 내서 최종 예측하는 기법



성능 개선 결과
(Accuracy)

Baseline
63.5%

+19.0%p 향상

개선 후
82.5%

03 Efficient CNN


EfficientNet-B0

Compound Scaling 적용 최적화 모델

HYUNDAI
AutoEver



04 사용 모델 | EfficientNet-B0



EfficientNet-B0 아키텍처

EfficientNet-B0

- 네트워크의 깊이, 너비, 해상도를 균형 있게 확장하는 **compound scaling**을 제안한 CNN 계열


선택 이유

- Compound scaling:** 깊이·너비·입력 해상도를 균형 있게 설계해 한 요소만 과도하게 키운 모델보다 효율적으로 특징을 추출
- MBConv 구조:** 적은 연산량으로 다양한 공간적 특징을 처리하므로 제품의 윤곽, 테두리, 폭 변화 같은 형태 정보를 추출하는 데 적합할 것으로 판단

모델	EfficientNet-B0
Pretrained weight	ImageNet Pretrained
크롤링 데이터셋 (전체/학습/테스트)	642 / 513 / 129
실촬영 데이터셋 (테스트)	126
입력크기	224 × 224
Epoch / batch	15 / 32
Optimizer	AdamW, LR: 0.0003, Weight decay: 0.0001
Scheduler	Cosine annealing

04 모델 개선 과정 | EfficientNet-B0

1. freeze → unfreeze




적용 이유

- 사전학습된 backbone에 도메인 특성을 학습시키기 위해
Unfreeze 적용

결과

- 실촬영 Test에서 성능 크게 향상(**69→79.4, +10%**)

2. 학습률에 따른 성능 비교



적용 이유

- 학습률 별 모델 성능 비교

결과

- 실촬영 Test에서 성능 크게 향상(**79.4→88.1, +약 9%**)

04 Lightweight CNN


MobileNetV3-Small

모바일/임베디드 최적화 경량 모델

HYUNDAI
AutoEver



04 사용 모델 | MobileNetV3-Small



MobileNetV3-Small

- 모바일 · 엣지 기기용으로 설계된 경량 이미지 분류 CNN, 스마트폰 CPU에서도 실시간으로 도는 것을 목표로 구조가 자동 탐색(NAS)된 모델


선택 이유

- 경량 · 고속 : CPU 추론 4.6 ms/장 → GPU 없는 엣지 PC에서 추론 가능
- 형상 4 클래스 분류에 충분 : mug / straight / taper_smooth / taper_step

모델	MobileNetV3-Small
Pretrained weight	ImageNet Pretrained
크롤링 데이터셋 (전체/학습/테스트)	642 / 513 / 129
실촬영 데이터셋 (테스트)	126
입력크기	224 × 224
Epoch / batch	12 / 16
Optimizer	AdamW, LR: 0.0003, Weight decay: 0.0001
Scheduler	Cosine annealing

04 모델 개선 과정 | MobileNetV3-Small

1. 입력 리사이즈 — 레터박스




적용 이유

- 라벨 규칙이 전부 **길이 비율**이다 (mug: 높이 $\leq$ 지름 $\times 1.5$)
- Resize((224,224))는 가로·세로 배율이 따로 논다

결과

- 라벨이 **비율**인 두 클래스(mug·straight)
- macro-F1도 같은 방향 — **92.5→96.0** · 실촬영 **64.3→71.4**

2. 증강 선택 — 라벨이 바뀌지 않는 것만



적용 이유

- 일반화 성능 향상 기대

결과

- 좌우반전 · 회전 $\pm 10^\circ$ (여백 흰색)
밝기 · 대비 · 채도 0.2 · 색상 0.02 (**1.5% 향상**)
- crop은 양쪽 다 손해 — 셋 다 차이는 2~3장 (**$p \geq 0.45$**)

05 Transformer


ViT (Vision Transformer)

Self-Attention 기반 비전 트랜스포머

HYUNDAI
AutoEver



04 사용 모델 | Vision Transformer



Vision Transformer 아키텍처

Vision Transformer (ViT)

- 자연어 처리의 Transformer를 컴퓨터 비전으로 확장한 딥러닝 모델

선택 이유

- 전역적 특징 포착:** self-attention으로 이미지 전체 영역 간의 관계를 처음부터 한 번에 학습
→ 객체 전체적인 실루엣 판별에 유리할 수 있음

모델	Vision Transformer DeiT-Small/16
Pretrained weight	ImageNet - 1k
크롤링 데이터셋 (전체/학습/테스트)	642 / 513 / 129
데이터 증강	좌우반전50% / 10도 회전
실촬영 데이터셋 (테스트)	126
입력크기	224 × 224
Epoch / batch	25 / 8
Optimizer	AdamW, LR: 0.00001 Weight decay: 0.01
Non-Scheduler	고정 차등 학습률

04 모델 개선 과정 | Vision Transformer

Key Model Improvements

01. 종횡비 보존 패딩

Crop 대신 회색 여백을 채워 물체 전체를 보존함으로써 핵심 이미지 정보 손실을 방지

02. freeze → unfreeze

전체 레이어를 재학습하는 대신 상위 레이어만 해당 프로젝트 도메인 특성에 맞춰 최적화 조정

03. 차등 학습률 (Differential LR)

사전 학습된 백본(Backbone)은 미세 조정하고, 새로 추가된 Head는 빠르게 학습하도록 분리 적용

04. Weight Decay (0.01)

정규화(Regularization) 기법을 강화하여 학습 데이터에 대한 과적합(Overfitting)을 효과적으로 억제

성능 개선 결과

베이스라인 Accuracy

73.0%

▲ +12.7%p

개선 후 Accuracy

87.5%

비전 트랜스포머 모델 최적화 달성

06 Modern CNN


ConvNeXt-Tiny

ViT 구조를 반영한 현대적 CNN 모델

HYUNDAI
AutoEver



04 사용 모델 | ConvNeXt-Tiny



ConvNeXt-Tiny 아키텍처

ConvNeXt-Tiny

- 큰 커널의 **depthwise convolution**과 계층적 **stage** 구성을 활용해 영상의 공간적 특징을 추출하는 현대적 CNN


선택 이유

- 직선형 윤곽, 완만한 폭 변화, 단차처럼 형태가 중요한 과제에서 **7×7 depthwise convolution**과 단계적 특징 추출이 넓은 형태 문맥을 포착하는데 도움이 될 것으로 기대
- **Depthwise convolution**은 공간 특징 추출의 연산 효율을 고려한 구조. 제한된 자원에서 충분한 표현력을 확보할 수 있을 것이라 기대

모델	ConvNeXt-Tiny
Pretrained weight	ImageNet Pretrained
크롤링 데이터셋 (전체/학습/테스트)	642 / 513 / 129
실촬영 데이터셋 (테스트)	126
입력크기	224 × 224
Epoch / batch	30 / 32
Optimizer	AdamW, LR: 0.0001, Weight decay: 0.0001
Scheduler	Cosine annealing
loss function	Cross Entropy Loss

04 모델 개선 과정 | ConvNeXt-Tiny

Baseline → v3 : RandomPerspective 증강 적용



ConvNeXt 베이스 라인

적용 이유

Baseline에서 **taper_smooth** 클래스 F1이 **0.33**으로 현저히 낮음


- taper_smooth는 점진적으로 가늘어지는 형태
→ 촬영 각도 변화에 외형이 크게 달라짐
- RandomPerspective 증강 추가
→ 다양한 시점 패턴을 학습 데이터에 반영

결과

- taper_smooth F1 **0.33 → 0.71 (+0.38)**
- Macro avg F1 **0.58 → 0.83 (+0.25)**
- 전체 Accuracy **60.1 → 82.9% (+22.8%)**

04 모델 개선 과정 | ConvNeXt-Tiny

v3 → v4 : RandomErasing + LLRD 적용



적용 이유

① RandomErasing(p=0.3)

- GradCAM 분석 → 모델이 배경에 과도하게 집중
- 랜덤 패치 제거로 배경 의존도 낮추고 형상 특징에 집중하도록 유도

② LLRD (Layer-wise LR Decay, decay=0.8)


- 하위 레이어일수록 더 낮은 LR 적용
→ 사전학습 특성 보존 + 상위 레이어 fine-tuning

결과

- taper_smooth F1 **0.71 → 0.78 (+0.07)**
- Macro avg F1 **0.83 → 0.86 (+0.03)**
- 전체 Accuracy **82.9 → 85.0% (+2.1%)**

04 모델 개선 과정 | ConvNeXt-Tiny

v4 → 최종 : val loss 기준 early stopping



적용 이유



① Val Loss 기반 Early Stopping

- Val acc 기준 → 정확도는 오를 때도 loss는 오를 수 있음 > val loss가 더 민감하게 과적합 감지

결과

- straight F1 **0.82 → 0.92 (+0.10)**
- Macro avg F1 **0.86 → 0.89 (+0.03)**
- 전체 Accuracy **85.4 → 88.9% (+3.5%)**

04 최종 결과 | ConvNeXt-Tiny



05 실험 결과 및 분석

05 실험 결과 및 분석 | 실촬영 데이터셋

결과 비교


모델		Rule-based	ResNet	EfficientNet	MobileNet	ConvNeXt	ViT
F1 Score	Mug	0.25	0.88	0.82	0.83	0.90	0.91
	Straight	0.21	0.69	0.88	0.71	0.92	0.83
	Taper smooth	0.00	0.85	0.82	0.62	0.82	0.85
	Taper step	0.08	0.90	0.96	0.75	0.91	0.92
Accuracy		0.18	0.83	0.88	0.71	0.89	0.88
macro F1 score		0.13	0.83	0.89	0.73	0.89	0.88
macro F1 score Δ (%p)		-47.60	-13.90	-9.58	-23.38	-3.93	-9.00

macro F1 score Δ : 실촬영으로 테스트한 값 - 학습에 쓰지 않은 웹 상품사진으로 테스트한 값

06 한계 및 보완 방향

06 한계 및 보완 방향 - 배경 식별 불가의 한계

결과 비교



객체와 배경이 색이 유사할 시
외형 탐지 성능 저하에 따른 오탐
case

원인



Train Data가 배경 없는
깨끗한 이미지 사용

보완법



- Train Data에 배경이 있는 Data를 추가해서 학습
- DL Model을 배경과 객체를 탐지성능을 고려한 Model Tuning


06 한계 및 보완 방향 - Taper Smooth 분류의 한계

결과 비교



입력 크기 변환 ->
원본 종횡비와 축벽
기울기가 변형 ->
형상 기하학적 특징 손실

원인



분류 자체는 대체로 잘
되어있는 모습

보완법

- 모델이나 전처리의 영향은 적다 판단
- 데이터 양적인 보완 필요

06 demo video(클릭)

HYUNDAI
AutoEver



Live Demo



Link 1



Link 2

Q&A

HYUNDAI
AutoEver



감사합니다.

HYUNDAI
AutoEver

